

FCN-BLA 모델에 기반한 교통량 분석 시스템

Traffic Analysis System based on FCN-BLA model

권태윤¹ 윤찬웅² 손홍일³ 김기태⁴

^{1,2} 한양대학교 ERICA 소프트웨어융합대학 소프트웨어학부 소프트웨어전공

^{3,4} 한양대학교 ERICA 소프트웨어융합대학 소프트웨어학부 컴퓨터전공

^{1,2,3,4} {kwonconnor101, qicqockqvgiq, hongil7626, kimkt0155}@gmail.com

요 약

지능형교통체계(ITS)를 구축하기 위해서 교통 정보의 실시간 수집 및 분석은 필수적으로 요구된다. 본 논문에서는 이러한 교통 정보의 실시간 수집 및 분석을 효율적이고 효과적으로 수행하기 위해 차량 계수 예측 모델 중 state-of-the-art 모델인 FCN-rLSTM 모델을 분석 및 개선하여 더 좋은 성능을 가지는 FCN-BLA 모델과 FCN-BLA 모델에 기반한 교통량 분석 시스템을 제안한다. 제안한 모델 및 시스템을 통해 다수의 실시간 도로 CCTV 영상을 병렬적으로 분석하고 또한, 사용자의 요청에 따라 분석 결과를 제공해줌으로써 기존 분석 방식들을 대체 할 수 있는 새로운 시스템으로서의 가치를 기대할 수 있다.

1. 서 론

지능형교통체계(ITS)는 교통수단의 실시간 관리, 제어와 교통 정보의 실시간 수집 및 활용을 통해 시민들의 교통편의 증진과 교통안전을 도모할 수 있도록 교통체계의 운영, 관리를 자동화 및 과학화하는 환경 친화적 미래형 교통체계이다[1]. 교통 정보의 실시간 수집 및 분석은 지능형교통체계를 구축하기 위해 요구되는 근본적인 구성요소이기에 이를 효율적이고 효과적으로 처리하기 위한 다양한 연구들이 수행되고 있다.

본 논문에서는 컴퓨터 비전 분야의 차량 계수 예측 모델 중 state-of-the-art(SOTA) 모델인 FCN-rLSTM[2] 모델에 기반하여 시간 역학적 정보를 더 효율적으로 참조 할 수 있는 새로운 모델인 'FCN-BLA' 모델과 해당 모델을 활용해 교통량을 분석할 수 있는 '교통량 분석 시스템'을 제안한다. 'FCN-BLA 모델에 기반한 교통량 분석 시스템'은 교통 정보의 실시간 수집 및 분석을 이행하는 기존 방식들의 문제점들인 비용적 부담, CCTV 영상의 외부적인 요인, 영상품질에 취약함, 수치적인 데이터의 부재를 해결하여 기존 방식들을 대체할 수 있는 새로운 시스템으로서의 가치를 가진다

FCN-BLA 모델을 활용한 교통정보의 수집은 다수의 실시간 CCTV 영상을 병렬적으로 처리하여 효율성을 증대시키며, '교통량 분석 시스템'은 수집한 데이터를 실시간으로 제공하거나 기간별 분석 결과 및 통합 데이터를 제공함을 통해 지능형교통체계를 구축하기 위한 분석자료로 활용할 수 있게 한다.

FCN-BLA 모델은 FCN-rLSTM 모델에 기반하여 Encoder-Decoder 구조에 양방향 LSTM 과 Attention 모듈을 접목한 모델로, 기존에 사용되던 LSTM 보다 복잡한 시간 역학적 정보를 더욱 잘 학습할 수 있도록 설계 되었으며, 대규모 교통 데이터셋인 TRANCOS[5]에서 차량 계수 평균 오차 범위(MAE)가 4.205로 4.38인 FCN-rLSTM[2] 보다 좋은 성능을 보인다.

본 논문에서는 2장에서 기존에 차량 계수를 측정하기 위해 사용되는 방식들에 대한 분석을 소개하며, 3, 4장에서는 FCN-BLA와 교통량 분석 시스템에 대한 설명을 진행하고, 최종적으로 5장에서 결론 및 향후 계획에 대해서 서술한다.

2. 기존 차량 계수 측정법 분석 및 문제 해결

차량 계수 정보를 수집하고 관리하는 기술은 전부터 다양한 접근을 통해 개발되었지만, 각 기술마다의 단점이 존재한다. 이번 장에서는 현재 개발된 기술들의 문제점과 현 ITS 서비스를 분석하고 이를 해결하기 위한 전략을 설명한다.

2.1 센서 방식

센서를 통해 차량의 교통정보를 수집하는 방식으로, 대표적으로 루프 센서를 이용한 측정 방식이 있다. 루프 센서는 차량 진입시 차량 도체에 의한 유도자장과 루프자장의 상호작용을 이용해 변화를 감지하여 차량을 감지한다. 센서의 감지성능이 우수하고 감도조절에 따른 차량 감지 조절이 가능하며 내구성이 강하다는 장점이 있다. 하지만, 센서의

설치와 관련 인프라 구축에 많은 비용을 소모하므로 넓은 범위의 도로 서비스 운용에는 적합하지 않다는 단점이 있다.

2.2 영상 검지 방식

도로 위 영상 촬영 장비를 통해 얻은 데이터로 차량을 검지하여 교통량을 측정하는 방식으로, 기존 장비만으로 운용이 가능하기 때문에 설치 비용이 상대적으로 저렴하며 유지 보수가 간단하다. 정확한 데이터만 수집된다면 영상 속 객체를 인식할 수 있기에 넓은 범위의 교통량 수집이 가능하다는 장점 또한 있다. 크게 객체를 검출하거나 동작을 감지하는 두 가지 방식을 통해 차량을 인식하며 대표적인 기술로는 검지 영역의 픽셀 변화량으로 차량을 검지하는 Tripwire 시스템이 있다. 도로 영상 수집만으로 차량 계수 측정이 가능하지만 영상 검지 방식의 특성상 외부 요인의 변화에 잘 대처하지 못하여 측정에 오류가 발생하는 경향이 있다. 또한 밝기, 해상도, 프레임률 등 영상의 품질에 영향을 미치는 속성들이 측정 성능에 민감하게 작용하므로 영상의 품질을 특정 기준 이하로 조정할 수 없어 CCTV와 같은 자원이 제한된 환경에서 정보를 수집하고 관리하는데 어려움이 있다.

2.3 국가 교통 정보 센터(ITS)

ITS 국가 교통 정보 센터는 각 도로에서의 차량 통과 속도를 이용해 교통 혼잡도를 3단계로 판단하고 이를 사용자에게 지도와 API 형태로 제공하고 있다. 차량의 속도 정보는 자체적으로 측정한 데이터와 민간에서 제공받은 데이터를 병합하여 우선순위에 따라 산출된다. 일반 사용자 입장에서는 현재 교통 상황을 ITS 시스템을 통해 직관적으로 파악할 수 있지만, 차량의 속도가 교통량과 직접적으로 비례하지 않아 정량적인 데이터를 수집할 수 없다. 또한 장기적인 측정 정보에 대한 열람과 분석이 가능한 시스템이 없어 도로 특성에 따른 통계 지표 확보가 어렵다.

2.4 요약 및 해결 전략

앞서 언급한 방식들의 문제점을 요약하면, 기존 차량 계수 측정 방식은 장비 설치에 비용적인 부담이 있고, 외부 요인에 강건하지 못하며, 영상의 품질에 의존적이라는 단점이 있다. 또한 ITS 서비스에서는 차량의 속도로 교통량을 추정하기에 정확한 교통량 정보를 파악하지 못하며 실시간 수집 및 분석이 가능한 시스템이 없다는 문제가 있다. 이에 따라 본 논문에서는 기존 방식들과 ITS 서비스의 문제점을 해결하기 위해 두 가지의 해결책을 제시한다.

첫번째는 교통량 정보의 정량적 데이터를 위해

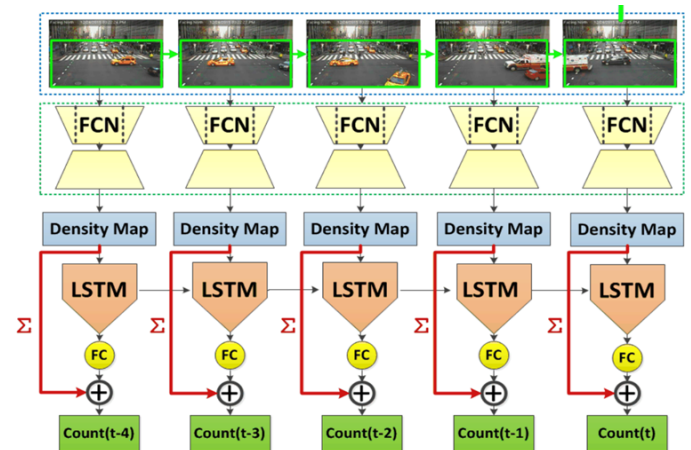
Computer Vision 분야의 딥러닝 모델을 사용한다. 모델은 차량 계수 측정 분야의 SOTA 모델인 FCN-rLSTM 모델을 기본 구조로 사용해 외부요인 변화와 영상의 품질에 민감하다는 기존 한계에 대처한다[2]. 추가로 FCN-rLSTM 모델을 분석하여 개선점을 발견하였고 이를 적용한 새로운 모델인 FCN-BLA 모델을 제안한다.

두번째는 위 딥러닝 모델을 활용한 교통량 분석 시스템을 제안하여 장기적인 측정 데이터를 관리하고 분석한다. 각 도로별로 모델의 예측 데이터를 정리하여 제공하는 기능을 구현하였고 이를 통해 기간별 통계 지표를 확보한다.

3. FCN - Bidirectional LSTM Attention(BLA)

3.1 FCN-rLSTM 모델

SOTA 모델인 FCN-rLSTM 모델은 fully convolutional neural networks(FCN)와 long short term memory networks(LSTM)를 잔차(residual)를 학습하는 방식을 통해 결합하여 차량의 계수를 예측하는 모델이다.



[그림 1] FCN-rLSTM 모델 구조

FCN은 기존 객체 검출이나 동작 감지 방식에서 차량 자체를 인식하는 알고리즘과 다르게 객체의 밀집도를 토대로 차량의 계수를 예측한다. FCN에서 밀집도를 측정하기 위한 방법은 크게 두 단계로 구성된다. 먼저 모델의 입력이 들어오면 모델은 특징 추출을 시작한다. 3x3 커널과 Max-Pooling을 통해 이미지에서 지역 정보를 압축하고 Dilated Convolution을 거쳐 데이터의 특징 정보를 추출한다. 그 후 추출된 레이어들 중 4개를 가져와 병합한 Hyper-Atrous Combination 레이어를 후처리하여 생성된 밀집도를 결과로 제공한다. Hyper-Atrous Combination 레이어를 예측에 사용하는 이유는 반복된 Max-pooling과 striding에 의해 특징 정보가 감소하여 하나의 레이어에서 가져온 특징 정보만으로는 밀집도를 예측하기 어

럽기 때문이다. 밀집도는 후처리 과정에서 입력 데이터와 같은 사이즈로 조정된 뒤 예측되기 때문에 픽셀 수준의 측정 정보를 포함하고 있어 기존 방식들에 비해 낮은 화질이나 프레임률에서 더욱 정확한 예측이 가능하다.



[그림 2] FCN-rLSTM 밀집도(Density map)

FCN 구조를 통해 기존 저품질 이미지 예측에서 발생하는 문제들을 해결하였지만, 차량의 계수를 밀집도의 모든 픽셀값의 합으로 구하기 때문에 넓은 시야각을 가지거나 대형 차량이 많이 통과하는 환경에서 픽셀의 합을 통한 차량 측정은 큰 오차를 발생시키는 경향이 있다. 이를 해결하기 위해 [그림 1]에서와 같이 FCN에 LSTM을 잔차 방식으로 결합하여 FCN에서 계산된 차량 밀집도와 LSTM의 시간 역학적 정보를 함께 모델에서 학습하는 end-to-end neural network로 설계하였다. 모델은 5개의 입력 이미지 배열을 받아 각 타임스탬프의 차량 밀집도와 개수를 예측하고 이 정보를 시간 순으로 전달하는 방식을 사용한다. 이전 이미지의 차량 밀집도 정보를 기억하여 현재 이미지의 차량 수 추론에 참조하는 구조를 통해 FCN의 문제점을 보완해 측정 정확도를 높인다.

3.2 FCN-rLSTM 한계점 분석

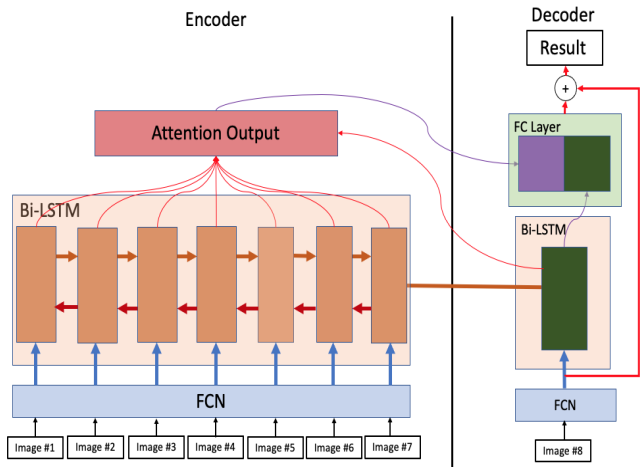
FCN-rLSTM에서 각 타임스탬프에 해당하는 LSTM은 FCN을 통해 산출된 차량 밀집도의 모든 픽셀의 합을 입력으로 받아 시간 역학적 정보를 추출한다. 추출된 시간 정보는 마지막 단계에서 FCN의 결과값과 병합되어 최종 차량 계수 예측 값을 산출한다[왼쪽 그림]. 이러한 모델 설계는 픽셀 단위의 정확한 예측과 복잡한 시간 역학적 정보의 학습을 가능케 한다는 장점이 있지만 두 가지의 한계점을 가지고 있다.

먼저 FCN-rLSTM 모델 구조상 LSTM의 결과가 하나의 고정된 크기의 벡터에 압축되어 전달되는 병목이 존재한다. 이는 LSTM을 통한 결과가 제한된

크기로 정보가 함축되어 다음 단계에 전달되므로 정보의 손실이 발생하고 입력 시퀀스가 길어짐에 따라 성능이 저하되는 현상이 나타난다. 또한 시간 흐름에 따른 단방향 LSTM은 한쪽 방향으로만 학습이 이루어져 결과값이 직전 정보만을 참조한다는 한계를 지니고 있다. 이는 입력 시퀀스가 길어지고 더 많은 LSTM이 쌓일수록 유실되는 시간 연속적 정보가 많아지는 문제점이 존재한다.

3.3 FCN-BLA 제안

본 논문에서는 앞서 언급한 FCN-rLSTM의 기본 LSTM 구조가 가진 한계점을 극복하고자 시간 역학적 정보를 더 효율적으로 활용할 수 있는 FCN-Bidirectional LSTM Attention(FCN-BLA) 모델을 제안한다. FCN-BLA 모델은 [그림 3]과 같이 기존 FCN-rLSTM에서 사용한 FCN과 LSTM에 추가적인 시간 역순 방향의 LSTM과 Attention 모듈을 접목하여 입력 이미지의 정보를 보다 효율적으로 추출하는 Encoder-Decoder 구조를 설계하였다. 기존과 반대되는 방향의 LSTM은 직전 정보뿐만 아니라 앞선 정보 또한 네트워크가 학습하여 입력 이미지 배열의 정보를 모델의 출력에 더욱 반영하도록 한다.



[그림 3] FCN-BLA 모델 구조

기존 Encoder의 정보가 마지막 LSTM에서만 전달되는 병목은 양방향 LSTM에 Attention 모듈을 적용해 모든 입력 이미지를 decoder가 직접 참조하도록 한다. Attention 모듈은 매 타임스탬프마다 생성되는 정보와 그에 따른 Attention의 가중치를 곱해 각각의 Encoder마다 다른 비율로 계산된 정보를 만들어내고 이를 통해 기존의 압축된 시간 역학적 정보를 더욱 효율적으로 전달할 수 있어 입력 데이터의 정보 손실을 최소화한다.

양방향 LSTM과 Attention 모듈을 통해 긴 입력 시퀀스와 다중 LSTM에도 복잡한 시간 연속적 정보를


잘 학습할 수 있다 판단하여 모델의 입력 배열 개수를 늘렸다. 배열의 개수를 5개부터 점차 늘려 모델의 성능을 평가하였고 이를 통해 시스템에 사용할 모델은 8개의 입력 배열을 받을때 가장 좋은 성능을 보임을 확인하였다.

3.4 모델 학습

FCN-BLA 모델은 대규모 교통정보 CCTV 데이터셋인 TRANCOS 데이터셋으로 학습하였다. TRANCOS 데이터셋은 다양한 장소에서 도로 정체구간을 담아 육안으로도 차량 계수 측정이 힘든 상황으로 이루어진 데이터셋이다. 데이터셋은 1200개 이상의 이미지와 각 이미지에서 차량의 위치를 표현한 텍스트로 구성된다.

$$\text{Global Loss} = \text{Density Loss} + \lambda * \text{Count Loss} \quad (1)$$

모델 학습에서 Loss는 [식]을 따라 계산된다. Density Loss는 FCN의 결과로 나온 밀집도와 객체 정보를 나타낸 Ground-truth 밀집도를 비교한 추정 오차이다. 밀집도의 각 픽셀값을 비교하여 Mean-Squared Error(MSE)로 오차를 측정한다. Count Loss는 모델의 최종 출력으로 예측된 차량 계수와 정답 계수를 MSE를 통해 계산한 오차이다. 최종적으로 Density Loss와 Count Loss를 합쳐 Global Loss가 구해지는데 이러한 방식은 차량의 예측 밀집도와 계수를 동시에 학습에 참여시키는 효과가 있다. Count Loss는 학습 가중치인 λ 가 곱해져 Density Loss와 다른 비율로 최종 Loss에 반영된다. λ 는 0.001일때 실험적으로 가장 좋은 성능을 보였다.



[그림 4] FCN-BLA 학습 Loss 그래프

3.5 모델 평가

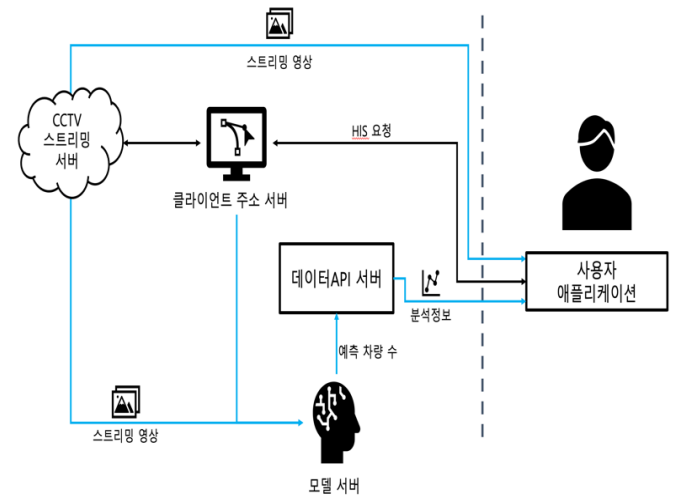
TRANCOS 데이터셋을 이용해 기존 SOTA 모델인 FCN-rLSTM과 FCN-BLA 모델을 Count Error로 비교하였다. 제안한 모델과 FCN-rLSTM을 비교하기 위해 FCN-rLSTM 논문[2]에 입각하여 학습을 진행하였으며, 학습에 쓰인 설정 또한 두 모델에서 동일하게 맞추어 진행하였다. FCN-rLSTM은 4.38, FCN-BLA는 4.205로, 새롭게 제안한 FCN-BLA은 TRANCOS 데이터셋에서 FCN-rLSTM 보다 좋은 성능을 가진다.

[표 1] FCN-rLSTM[2]모델과 FCN-BLA모델 MAE 비교

TRANCOS	FCN-rLSTM	FCN-BLA
Count Error (MAE)	4.38	4.205

4. 교통량 분석 시스템

4.1 시스템 개요



[그림 5] 시스템 전체 개요도

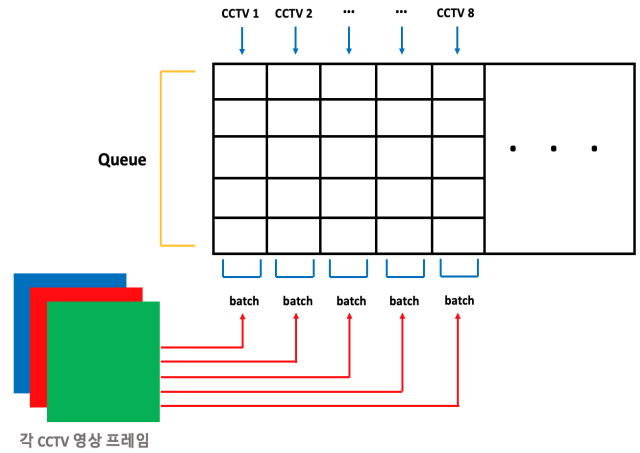
본 시스템은 [그림 1]과 같은 개요를 가진다. CCTV 스트리밍 서버는 국가교통정보에서 제공하는 대한민국 실시간 교통 CCTV 영상[3]을 사용했으며, 이는 HTTP 라이브 스트리밍(hls)을 통해 실시간 영상을 제공한다. 이러한 영상은 사용자의 실시간 분석 작업과 모델 서버에서의 실시간 데이터 수집 작업을 진행하는 경우에 사용이 된다. 모델 서버에서는 클라이언트 주소 서버에서 제공받은 CCTV 스트리밍 서버의 hls 주소 정보를 통해 실시간 영상을 받아오게 된다. 이를 1 fps로 프레임을 추출한 후, FCN-rLSTM[2] 모델을 사용하여 영상 속 차량 수를 예측하며 모델 예측 데이터는 소켓 통신에 기반하여 데이터 API 서버로 1초 간격으로 전달한다. 데이터 API 서버에서는 전달받은 데이터를 CCTV 마다 배열에 저장하며, 1시간 단위로 파일 시스템에 CSV 파일 형태로 저장시키도록 설계를 하였으며 또한, 사용자의 요청에 따라 특정 CCTV의 실시간 분석 결과 혹은, 기간별 분석 데이터를 사용자에게 제공해주는 기능을 가진다. 사용자 애플리케이션에서는 실시간 분석 영상을 보여주는 기능과 기간별 분석 데이터를 보여주는 기능을 제공하도록 설계를 하였다. 본 시스템은 기능 별로 서버를 분리하여 구축하였기 때문에 Data Server는 Streaming에 장애가 발생해도 데이터 기반 그래프는 지속적으로 제공이 가능하며 Model Server의 모델 파일과 모델 코드만 변경해주면 시스템에 새로운 딥러닝 모델을 적용할 수

있기에 변경이 수월하다는 이점을 가진다.

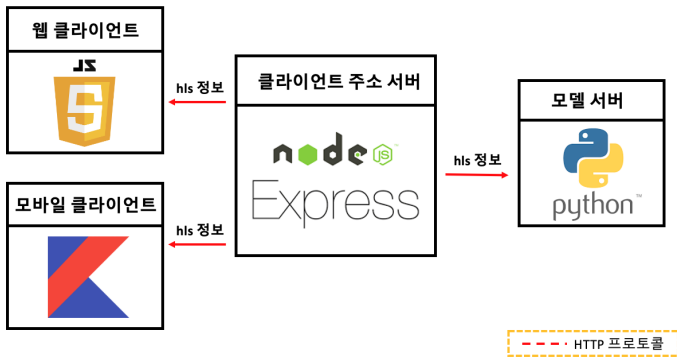
4.2 클라이언트 주소 서버

클라이언트 주소 서버에서의 클라이언트는 시스템을 사용하는 사용자와 모델 서버에 해당되며 스트리밍을 위한 hls 주소를 보유하고 배포하는 역할을 한다. 해당 서버는 처음 구동할 때 hls 주소를 요청한다. hls 주소는 클라이언트를 위한 주소와 Model Server를 위한 주소로 구분되어 저장한다. 그리하여, [그림 6]와 같은 개요로 클라이언트의 요청에 따라 보유하고 있는 hls 주소를 HTTP GET 메소드를 통해 JSON 또는 JSON String 형식으로 전송하게 된다. 또한 사용자가 Web을 통해 main페이지를 HTTP GET으로 요청시 라우팅을 한다.

전달하게 된다.



[그림 7] FCN-BLA 모델의 입력 형태



[그림 6] 클라이언트 주소 서버 데이터 흐름도

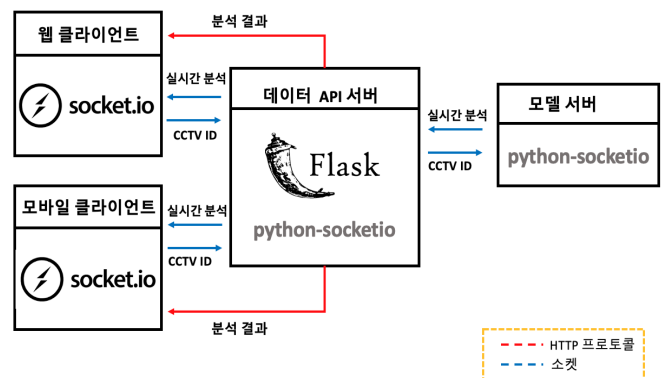
4.3 모델 서버

제안한 시스템의 모델 서버에서는 실시간 CCTV 영상을 받기 위해 클라이언트 서버에서 CCTV 스트리밍 서버의 hls 주소 정보를 받아오게 된다. 영상 정보는 cctv마다 하나의 Thread가 할당되어 frame을 읽는다. 이때, 1초마다 한번씩 가장 최근 frame까지 읽어들이며 물리적 딜레이로 인한 frame 지연을 방지한다. 또한, client가 스트리밍을 할 때 딜레이가 있는 것을 고려하여 최근 5개의 frame을 각 Thread안에 있는 큐에 넣어 딜레이를 맞춰 실시간 이미지 처리에 문제가 없게 한다. FCN-BLA 모델은 양방향 LSTM 구조를 사용하기에 연속된 이미지 배열을 입력으로 요구한다. 모델은 배열의 크기가 8일때 가장 뛰어난 성능을 보이기에[2] CCTV 영상에서 추출한 실시간 프레임을 크기가 8인 큐 배열에 넣게 되며, 이렇게 얻은 큐 배열을 모델의 입력 요소로 사용하게 된다. 이 와 같은 과정을 여러 CCTV 영상에 동시 적용함으로써 [그림 7]과 같은 형태인 크기가 8인 큐가 여러 개 겹친 텐서를 모델의 입력으로 사용하며 모델을 통해 CCTV 개수와 동일한 출력 결과의 개수를 얻게 된다. 이렇게 얻게 된 데이터는 소켓 통신 기반으로 데이터 API 서버로

4.4 데이터 API 서버

데이터 API는 Flask 프레임워크로 구축하였으며 [그림 8]과 같은 개요로 사용자 및 모델 서버와 통신하고 두 가지 작업을 수행한다. 한 가지는 모델 서버에서 전달 받은 데이터를 파일 시스템을 이용하여 {CCTV 이름/ 연도/ 월/ 일} 순서대로 세부 폴더에 나누어 CSV 파일로 저장하는 작업을 진행하며, 다른 한 가지 작업은 사용자가 특정 CCTV의 실시간 분석 결과 혹은 기간에 대한 분석 데이터를 요청 시 제공해주는 작업을 진행한다.

모델의 예측 데이터를 실시간으로 저장하기 위해서는 먼저 각 CCTV 마다 교통량 데이터를 저장하는 배열을 필요로 한다. 각 배열에는 (시간, 차량 수 예측 결과) 데이터를 저장하며 1시간 마다 CSV 파일로 저장한다. 본 서버는 모델 서버에서 예측 결과를 소켓 통신 기반으로 1초 마다 전달 받기에 저장 과정을 별도의 스레드를 이용해 비동기적으로 처리함으로써 실시간 데이터 수집 작업에 문제가 발생하지 않게 한다.



[그림 8] 데이터 API 서버 데이터 흐름도

사용자가 특정 CCTV에 대한 실시간 분석 결과를 요청하는 경우에는 모델 서버에서 들어오는 예측 결과를 사용자에게 소켓 통신 기반으로 즉시 전달한다. 사용자가 기간별 분석 데이터를 요구하는 경우에는 분석 과정을 별도의 스레드를 통해 진행하여 시간-차량 수 그래프와 시간 당 평균 차량 수를 HTTP 프로토콜 기반으로 전달하게 된다.

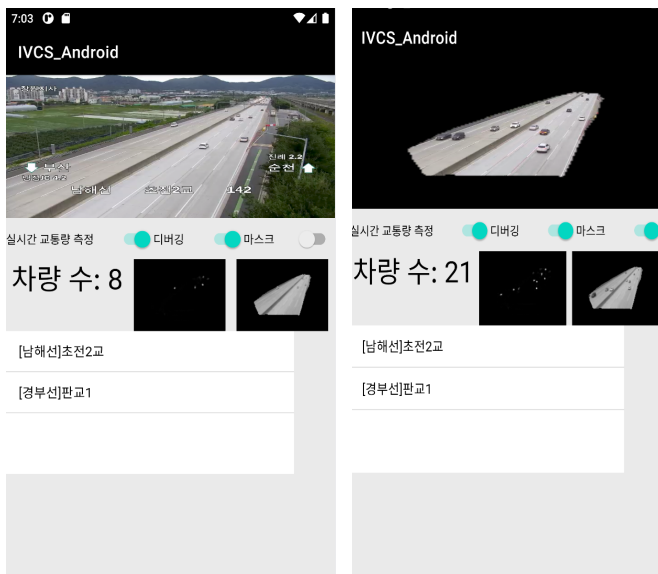
4.5 사용자 애플리케이션

사용자 애플리케이션은 웹과 안드로이드 환경을 지원하며 선택한 CCTV에 대한 실시간 영상 및 예측 결과를 보여주는 기능과 기간별 분석 데이터를 보여주는 기능을 보여준다.

기간별 특성 데이터는 특정 CCTV와 기간을 선택하게 된다면 HTTP POST 통신으로 시간과 CCTV의 정보를 담아 데이터 서버에 그래프를 요청하게 된다. 데이터 서버의 응답으로 해당 기간의 시간-차량 수 그래프와 시간 별 평균 차량 수 데이터를 전달받게 된다. 이렇게 전달 받은 데이터는 [그림 3]과 같이 사용자 애플리케이션에서 보여지게 된다. 이를 통해 특정 기간의 교통량을 파악 및 분석할 수 있으며 이를 활용하면 지능형 교통체계를 구축하는데 많은 도움을 줄 것으로 판단된다.

4.5.1 안드로이드 환경

안드로이드 애플리케이션을 처음 실행할 때 클라이언트 주소 서버에서 스트리밍에 필요한 hls 주소와 cctv 이름을 받아와 전역으로 보유한다. 만약 정보를 받아오지 못했다면 다음 화면으로 넘어갈 수 없고 사용자가 다음 화면을 요청할 시 클라이언트 주소 서버에 정보를 다시 요청하게 된다.



[그림 9] '[남해선] 초전2교' CCTV의 사용자 애플리케이션 실시간 분석 실행 화면

실시간 분석 영상은 원하는 CCTV를 선택하면 CCTV 스트리밍 서버에서 hls 프로토콜을 통해 받아온 실시간 영상을 스트리밍한다. 사용자는 실시간 교통량 측정, 디버깅, 마스크 버튼을 추가로 누를 수 있다. 실시간 교통량 측정 버튼을 누르게 되면 Data Sever와 socket 통신이 열려있는지 확인한 후 일정 시간마다 해당 cctv의 최신 차량 수에 대한 정보를 요청하게 된다. 디버깅 버튼은 실시간 교통량 측정이 진행중일 때만 활성화 할 수 있으며 FCN-BLA 모델에 어떤 이미지가 들어가고 어떤 density map이 나오는지 보여준다. 마스크 버튼을 활성화하면 실제 모델이 차량의 개수를 세는 영역만을 보여준다. 이를 통해 사용자는 실제 도로의 모습을 시각적으로 볼 수 있고 현재 차량이 약 몇 대인지 알 수 있다. 또한 density map과 스트리밍에 mask를 씌운 영상을 제공함으로써 모델에 대한 신뢰도를 얻을 수 있다.

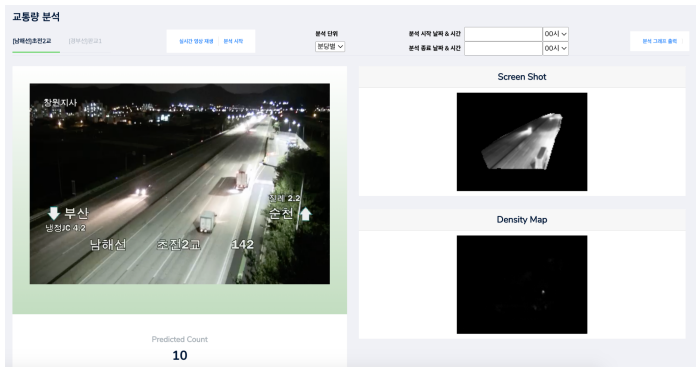


[그림 10] '[남해선] 초전2교' CCTV의 2022.06.03 15~2022.06.06 22시 데이터 분석 실행 화면

4.5.2 웹 환경


사용자가 웹에 접속하면 웹은 클라이언트 주소 서버에서 hls 주소와 cctv 이름을 제공받아 동적으로 cctv 선택 버튼을 생성하며 Data API 서버와의 소켓을 생성한다. '실시간 영상 재생' 버튼에서 onClick 이벤트가 발생할 경우 웹은 HTTP Live Streaming 기능을 포함한 JavaScript 라이브러리인 hls.js를 활용하여 실시간 영상을 제공한다. 해당 영상은 CCTV 스트리밍 영상 서버와 사용자의 네트워크 상태에 의존한다. '분석 시작' 버튼에서 onClick 이벤트가 발생하면 2000ms 간격으로 선택된 cctv id값을 Data Server에

분석 값을 요청하며 Data API 서버는 웹 사용자에게 {차량 수 예측 결과, 예측 결과의 모델 입력 값, 예측 결과의 density map}을 전송한다. 웹은 Data API 서버에게 받은 정보를 사용자에게 시각적으로 제공하며 cctv를 변경할 경우 해당 ‘분석 시작’ 버튼으로 인해 생겨난 Interval은 종료된다. [그림 11]와 같이 사용자는 실시간 영상과 실시간 분석 정보를 동시에 제공받을 수 있다.



[그림 11] 실시간 영상 & 분석 정보 실행 화면

‘분석 그래프 출력’ 버튼의 onClick 이벤트는 사용자에게 분석 정보를 제공받아 분석 그래프를 제공한다. 사용자는 해당 버튼을 클릭하기 전에 필수적으로 분석 단위(분, 시간, 일), 분석 시작 날짜 및 시간, 분석 종료 날짜 및 시간을 선택해야한다. 분 단위로 분석할 경우 x축 정보를 제공받을 수 없다. [그림 12]와 같이 사용자의 요청에 따라 Data API 서버에서 생성된 분석 그래프를 사용자에게 시각적으로 제공한다.



[그림 12] ‘[남해선] 초전2교’ CCTV의 2022.06.04 00~23시 데이터 분석 실행 화면

시간 정보를 다시 입력해주세요.

[그림 13] 잘못된 정보에 대한 제공받는 오류 이미지

Data API 서버는 사용자에게 잘못된 정보를 제공받으면 사용자에게 오류 이미지를 전달하며 오류 이미지는 [그림 13]와 같다. 잘못된 정보는 1) 분석 시작 날짜 및 시간이 분석 종료 날짜 및 시간보다 미래일 경

우 2) 요청한 분석 날짜의 데이터를 Data API 서버가 보유하지 않는 경우와 같다.

5. 결론 및 향후 계획

본 논문에서는 지능형교통체계(ITS)를 구축하고 향상시키기 위해 새로운 딥러닝 모델인 ‘FCN-BLA’와 ‘FCN-BLA 모델에 기반한 교통량 분석 시스템’을 제안하였다. FCN-BLA 모델에서는 기존 교통량 측정법과 ITS 서비스의 문제점 뿐만 아니라 현재 vehicle counting 분야의 SOTA로 제시된 FCN-rLSTM 모델의 한계점을 개선하였다. FCN-BLA 모델에 기반한 교통량 분석 시스템은 다수의 실시간 도로 CCTV 영상을 병렬적으로 분석하며, 사용자의 요청에 따라 실시간 분석 결과 혹은 기간별 분석 데이터를 제공하여 지능형교통체계의 필수적인 요구사항인 교통량의 실시간 수집 및 분석을 만족하였다. 제안한 모델과 이를 활용한 시스템은 실시간 교통 정보의 수집 및 활용을 도와 지능형교통체계를 운영하는 데에 있어 기존 분석 방식들을 대체 할 수 있는 새로운 시스템으로서의 가치를 기대할 수 있다.

향후 계획으로는 본 교통량 분석 시스템을 통해 교통량 데이터가 충분히 쌓이게 된다면 보다 다각적인 분석을 통해 현재로서는 부족한 분석 결과를 추가로 제공할 예정이며, 이는 지능형교통체계를 구축하는 데에 필수적인 교통 정보의 분석에 많은 도움을 줄 것이라 판단된다.

6. 참고 자료 및 문헌

- [1] 국토교통부. https://www.molit.go.kr/USR/policyData/m_34681/dtl?id=406
- [2] Shanghang Zhang, Guanhang Wu, Joao P Costeira, and Jose MF Moura. Fcn-rlstm: Deep spatio-temporal neural networks for vehicle counting in city cameras. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 3667–3676, 2017.
- [3] 국가교통정보. <https://www.its.go.kr/map/cctv>
- [4] Shanghang Zhang, Guanhang Wu, Joao P Costeira, and Jose MF Moura. Understanding traffic density from large-scale web camera data. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 5898–5907, 2017.
- [5] Daniel Onoro-Rubio, Roberto J. Lopez-Sastre. Towards perspective-free object counting with deeplearning. In European Conference on Computer Vision, pages 615–629. Springer, 2016